

## 第7章 支持向量机

7.1 对于样本空间中的一划分超平面  $\mathbf{w}^T \mathbf{x} + b = 0$ , 有  $\mathbf{w} = (-1, 3, 2)$ ,  $b = 1$ 。则判断如下向量是否为支持向量, 并求出间隔。

(1)  $\mathbf{x}_1 = (4, -2, 2)$

(2)  $\mathbf{x}_2 = (2, 5, -6.5)$

(3)  $\mathbf{x}_3 = (4, -2, 4)$

解答: 使下列公式满足等号的样本成为“支持向量”

$$\begin{cases} \mathbf{w}^T \mathbf{x}_i + b \geq +1, & y_i = +1; \\ \mathbf{w}^T \mathbf{x}_i + b \leq -1, & y_i = -1. \end{cases}$$

(1)  $\mathbf{w}^T \mathbf{x}_i + b = -1 * 4 + (-2) * 3 + 2 * 2 + 1 = -5$ , 显然不是

(2)  $\mathbf{w}^T \mathbf{x}_i + b = -1 * 2 + 3 * 5 + 2 * (-6.5) + 1 = 1$ , 满足条件, 是支持向量

(3)  $\mathbf{w}^T \mathbf{x}_i + b = -1 * 4 + 3 * (-2) + 2 * 4 + 1 = -1$ , 满足条件, 是支持向量

$$\text{间隔} \gamma = \frac{2}{\|\mathbf{w}\|} = \frac{2}{\sqrt{1+9+4}} = \frac{\sqrt{14}}{7}$$

7.2 假设输入空间是  $\mathbf{R}^2$ , 核函数是  $\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z})^2$ , 试找出其相关的特征空间  $\mathcal{H}$  和映射  $\Phi(\mathbf{x})$ :

1) 取特征空间  $H = \mathbf{R}^3$ , 记  $\mathbf{x} = (x^{(1)}, x^{(2)})^T, \mathbf{z} = (z^{(1)}, z^{(2)})^T$ , 而

$$(\mathbf{x} \cdot \mathbf{z})^2 = (x^{(1)} z^{(1)} + x^{(2)} z^{(2)})^2 = (x^{(1)} z^{(1)})^2 + 2x^{(1)} z^{(1)} x^{(2)} z^{(2)} + (x^{(2)} z^{(2)})^2,$$

所以我们得到映射  $\phi(\mathbf{x}) = ((x^{(1)})^2, \sqrt{2} x^{(1)} x^{(2)}, (x^{(2)})^2)^T$ , 易得核函数

$$\phi(\mathbf{x}) \cdot \phi(\mathbf{z}) = (\mathbf{x} \mathbf{z})^2 = K(\mathbf{x}, \mathbf{z})$$

2) 取特征空间  $H = \mathbf{R}^3$ , 映射还可以为

$$\phi(\mathbf{x}) = \frac{1}{\sqrt{2}} ((x^{(1)})^2 - (x^{(2)})^2, 2x^{(1)} x^{(2)}, (x^{(1)})^2 + (x^{(2)})^2)^T$$

3) 取特征空间  $H = \mathbf{R}^4$ , 映射此时为  $\phi(\mathbf{x}) = ((x^{(1)})^2, x^{(1)} x^{(2)}, x^{(1)} x^{(2)}, (x^{(2)})^2)^T$

7.3 设计几种 SVM 实现多分类的方案。

SVM 多分类的实现主要从两种思路:

1) 直接法, 也即直接修改目标函数, 将多分类的参数通过计算合并到一个最优化的问题, 通过对这个问题的求解得到多分类的结果

- 2) 间接法，也即组合多个二分类器实现多分类。通过查阅资料可得间接法主要有 one-against-one 和 one-against-all 两种方法

- 一对多法 (one-versus-rest, 简称 OVR SVMs)

训练时依次把某个类别的样本归为一类,其他剩余的样本归为另一类,这样  $k$  个类别的样本就构造出了  $k$  个 SVM。分类时将未知样本分类为具有最大分类函数值的那类。

假如我有四类要划分 (也就是 4 个 Label), 他们是 A、B、C、D。

于是我在抽取训练集的时候, 分别抽取

- (1) A 所对应的向量作为正集, B, C, D 所对应的向量作为负集;
- (2) B 所对应的向量作为正集, A, C, D 所对应的向量作为负集;
- (3) C 所对应的向量作为正集, A, B, D 所对应的向量作为负集;
- (4) D 所对应的向量作为正集, A, B, C 所对应的向量作为负集;

使用这四个训练集分别进行训练, 然后得到四个训练结果文件。

在测试的时候, 把对应的测试向量分别利用这四个训练结果文件进行测试。最后每个测试都有一个结果  $f_1(x), f_2(x), f_3(x), f_4(x)$ 。于是最终的结果便是这四个值中最大的一个作为分类结果。

- 一对一法 (one-versus-one, 简称 OVO SVMs 或者 pairwise)

其做法是在任意两类样本之间设计一个 SVM, 因此  $k$  个类别的样本就需要设计  $k(k-1)/2$  个 SVM。当对一个未知样本进行分类时, 最后得票最多的类别即为该未知样本的类别。

假设有四类 A,B,C,D 四类。在训练的时候我选择 A,B; A,C; A,D; B,C; B,D; C,D 所对应的向量作为训练集, 然后得到六个训练结果, 在测试的时候, 把对应的向量分别对六个结果进行测试, 然后采取投票形式, 最后得到一组结果。

投票是这样的:

$A=B=C=D=0$ ;

(A,B)-classifier 如果是 A win, 则  $A=A+1$ ; otherwise,  $B=B+1$ ;

(A,C)-classifier 如果是 A win, 则  $A=A+1$ ; otherwise,  $C=C+1$ ;

...

(C,D)-classifier 如果是 C win, 则  $C=C+1$ ; otherwise,  $D=D+1$ ;

The decision is the  $\text{Max}(A,B,C,D)$

分别选取两个不同类别构成一个 SVM 子分类器, 这样对于  $K$  个类别来说, 共有  $(k*(k-1)/2)$  个分类器。在构造  $i$  和  $j$  的分类器时, 可以将类别  $i$  的训练样本置为 1,  $j$  的样本置为 -1 来进行训练。

在进行测试的时候, 使用最多的就是 Friedman 提出的投票策略: 将测试数据  $x$  对所有的分类器分别进行测试, 若由得到  $x$  属于第  $i$  类, 则第  $i$  类加 1, 属于  $j$  类, 则第  $j$  类投票加 1。累计各类别的得分, 选择得分最高者所对应的类别为测试数据的类别。